Промежуточный отчет по проекту

Эффективность speculative decoding и prompt lookup для summarization

Курс: Эффективные системы ML
Дата: 30 марта 2026
Участники: Добрецов Борис Владимирович (tg: @DGAPer)
Статус: первый реализованный эксперимент

Краткий вывод. На задаче summarization prompt lookup уже ускоряет генерацию относительно baseline (1.27x), тогда как classical speculative decoding с draft-моделью в текущей реализации остается медленнее baseline для всех протестированных precision.

1. Цель и постановка задачи

Цель проекта - сравнить несколько способов ускорения генерации LLM: обычный baseline decoding, classical speculative decoding с отдельной draft-моделью и prompt lookup decoding. На текущем этапе проведен первый блок экспериментов только для задачи summarization.

2. Конфигурация первого эксперимента

- Target model: Qwen/Qwen2.5-3B-Instruct.
- Draft model: Qwen/Qwen2.5-0.5B-Instruct.
- Число примеров: 20.
- Средняя длина prompt: 157.4 токена.
- Средняя длина генерации: 67-70 токенов.
- Сравниваемые режимы: baseline, speculative (bf16/int8/int4), prompt lookup.

3. Результаты

3.1. Сводная таблица

Режим	Precision	ms/token	Speedup vs baseline	Acceptance rate	Peak VRAM, GB
baseline	baseline	23.50	1.00x	-	5.78
speculative	bf16	44.83	0.52x	0.526	6.69
speculative	int8	168.21	0.14x	0.526	6.36
speculative	int4	69.39	0.34x	0.509	6.20
prompt_lookup	prompt_lookup	18.46	1.27x	-	5.78

По первому эксперименту лучший результат показывает prompt lookup decoding: 18.46 ms/token против 23.50 ms/token у baseline. Лучший вариант model-based speculative decoding - bf16 draft, но он все равно медленнее baseline почти в 1.9 раза.

Рисунок 1. Сравнение latency per token для baseline и speculative

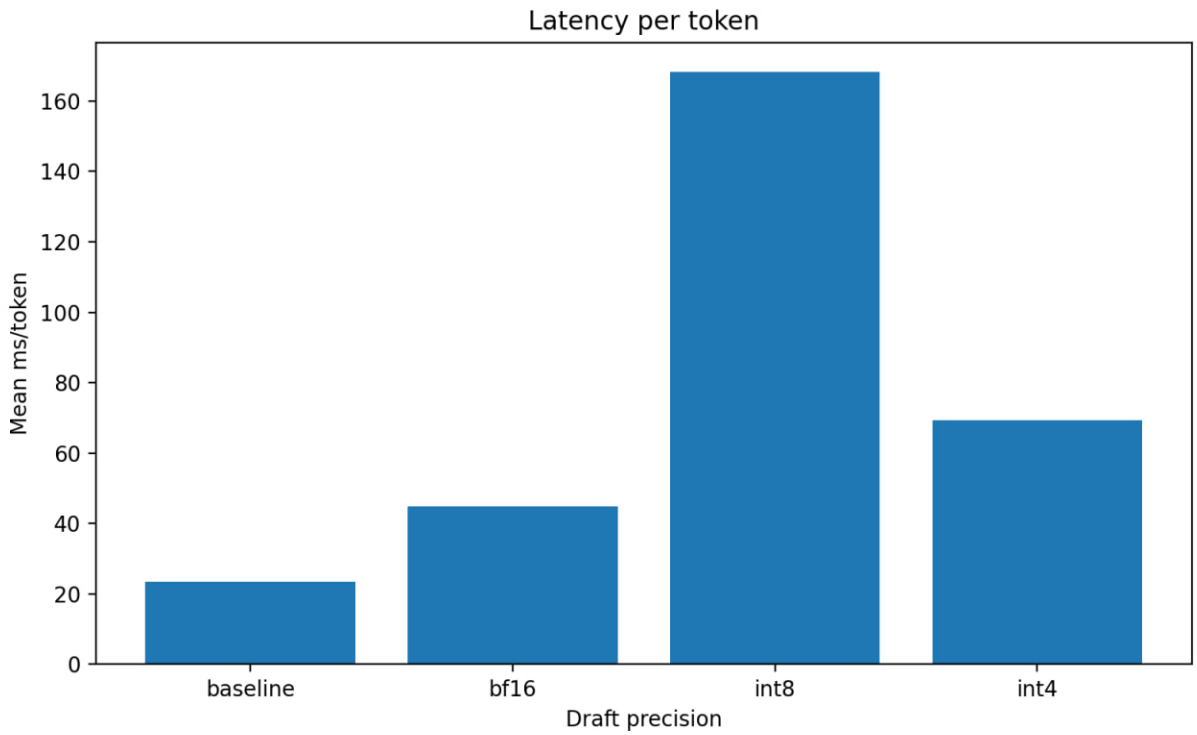

Рисунок 2. Acceptance rate для speculative decoding

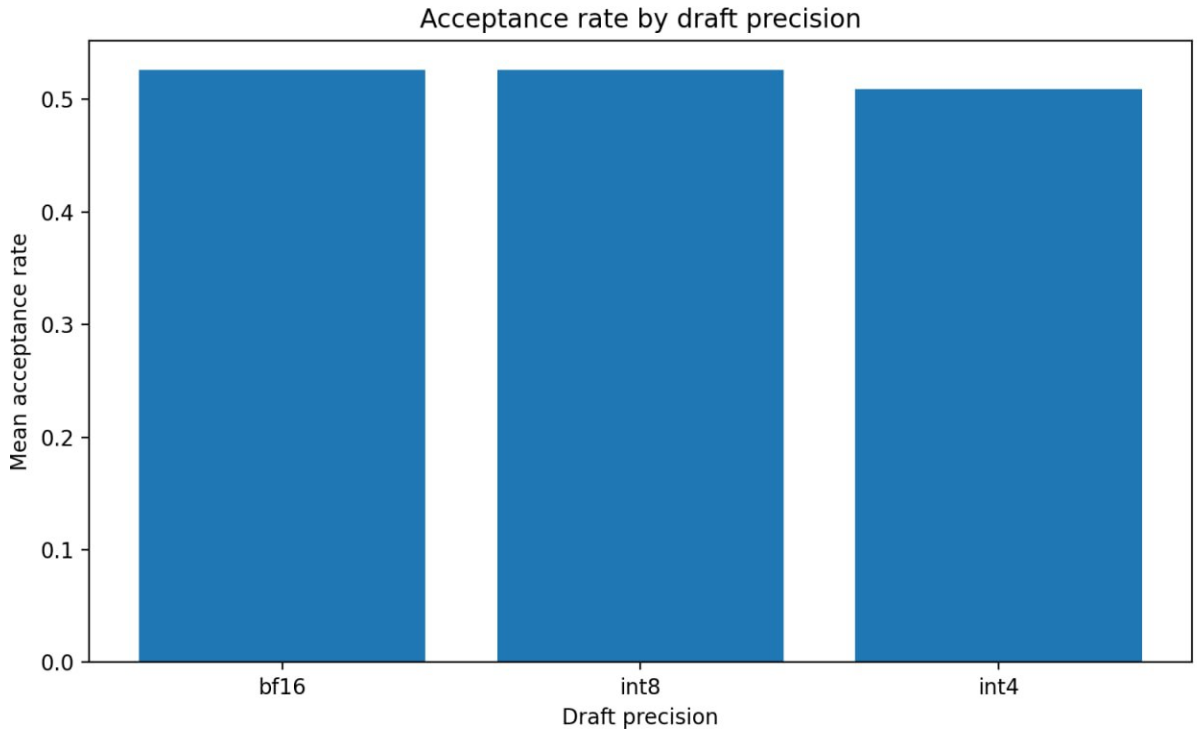

Рисунок 3. Draft time vs target time

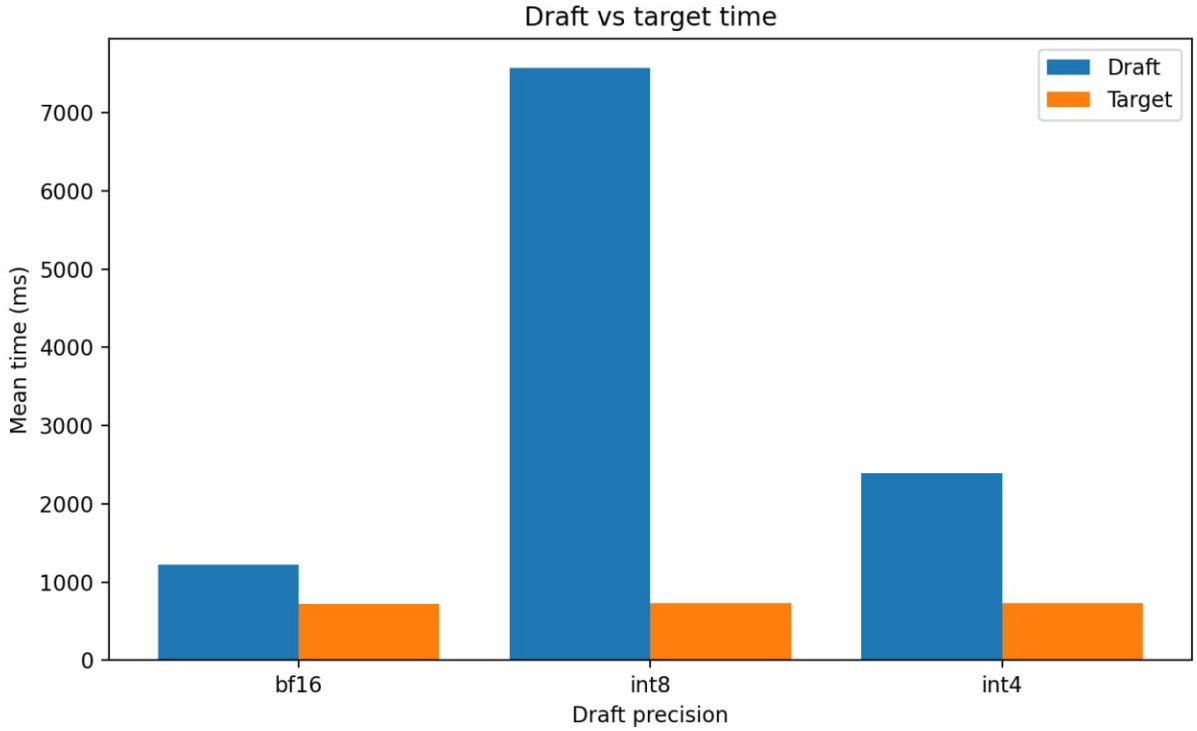

Рисунок 4. Сравнение baseline и prompt lookup по latency

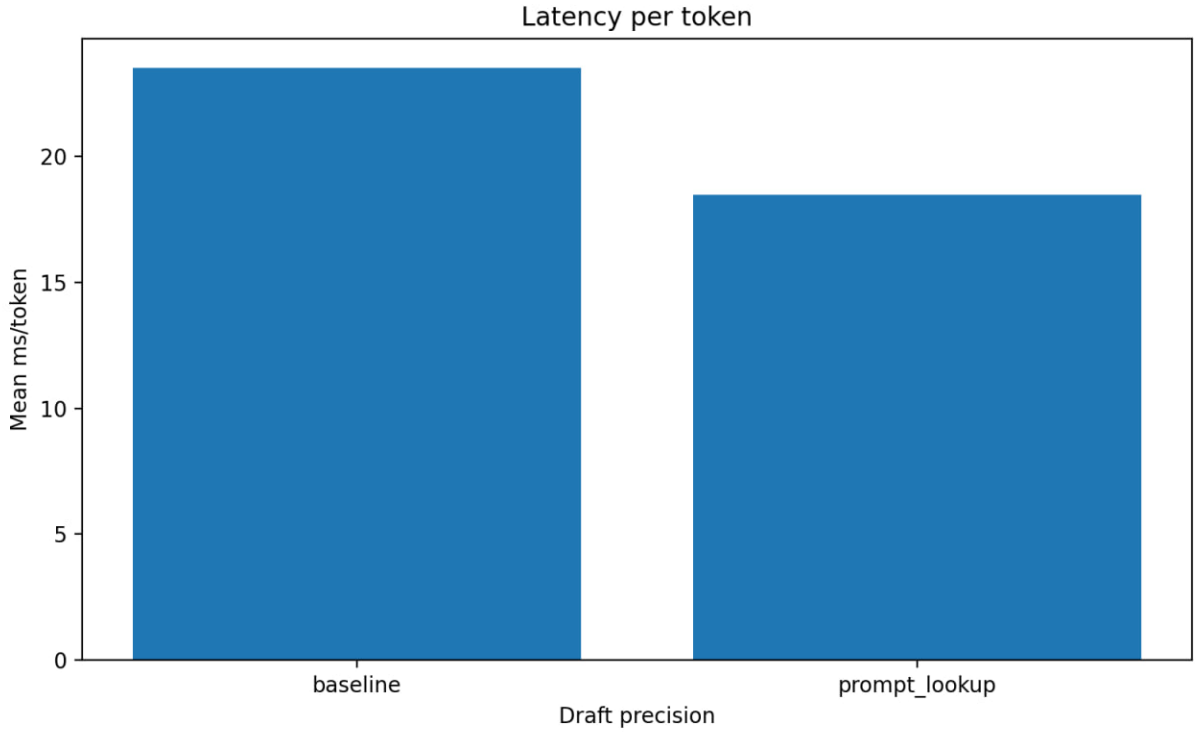

4. Интерпретация промежуточных результатов

Первые результаты показывают, что classical speculative decoding в текущей реализации пока не дает ускорения на summarization. Главная причина - draft-часть остается слишком дорогой, а acceptance rate находится только на уровне около 0.51-0.53, поэтому target принимает в среднем около 1.5 токена за итерацию. Напротив, prompt lookup оказался эффективнее baseline, что хорошо согласуется с природой summarization как input-grounded задачи.

Что уже понятно	Что еще нужно проверить
Для summarization prompt lookup является более сильным кандидатом на ускорение, чем отдельная draft-модель.	Нужно повторить сравнение на translation и math, а также добить sweep по параметрам speculative decoding.

5. План дальнейшей работы по неделям

Период	Основные задачи	Ожидаемый результат
30.03 - 05.04	Доделать summarization: sweep по K, добить графики, оформить промежуточный отчет.	Стабильный пайплайн и краткий PDF/Word-отчет.
06.04 - 12.04	Запустить baseline, speculative и prompt lookup на translation.	Полный набор результатов по второй input-grounded задаче.
13.04 - 19.04	Запустить baseline и speculative на math, собрать межзадачное сравнение.	Таблицы и графики по трем задачам.
20.04 - 25.04	Финальные прогоны, README, GitHub, итоговый PDF и презентация.	Полный пакет к сдаче 25 апреля и к очной защите.

6. Что должно войти в финальную версию проекта

- Сравнение baseline, speculative decoding и prompt lookup на summarization и translation.
- Сравнение baseline и speculative decoding на mathematical reasoning.
- Графики latency, speedup, acceptance rate, draft vs target time и VRAM.
- Репозиторий с кодом, инструкциями запуска и итоговой презентацией.

7. Краткий вывод

На текущем этапе strongest result состоит в том, что для summarization prompt lookup уже превосходит baseline и заметно превосходит classical speculative decoding с отдельной draft-моделью. Это делает prompt lookup важной частью дальнейшего исследования. Следующие шаги - проверить, сохраняется ли этот результат на translation, и понять, как ведет себя speculative decoding на более сложной задаче mathematical reasoning.